Université Moulay Ismail

Faculté des Sciences et Techniques d'Errachidia

Master SIDI

RAPPORT DE PROJET

Entrepôt de Données et Analyse Business Intelligence

Application : Africa Cup of Nations 2025 - Maroc

MySQL 8.0 - Talend Open Studio - Microsoft Power BI

Présenté par :

BOUKOTOS AKRAM

HASKOUK SOUFIAN

OULBERJ HASSANE

Encadré par :

Pr. FERHAOUI SOUSSEF

Année scolaire : *2025-2026*

Table des Matières

1. **Introduction au Projet**
   - 1.1 Contexte et Objectifs
   - 1.2 Périmètre du Projet
   - 1.3 Technologies Utilisées
2. **Sources de Données - Collecte et Preparation**
   - 2.1 Méthodes de collecte (scraping / téléchargement)
   - 2.2 Description des fichiers CSV
   - 2.3 Qualité et nettoyage des données
3. **Architecture et Méthodologie ETL**
   - 3.1 Vue d'ensemble de l'architecture
   - 3.2 Méthodologie ETL
   - 3.3 Modèle en Etoile (Star Schema)
4. **Integration ETL avec Talend Open Studio**
   - 4.1 Presentation de Talend
   - 4.2 Jobs ETL - Tables de Dimensions
   - 4.3 Jobs ETL - Tables de Faits
   - 4.4 Gestion des Erreurs
5. **Conception de l'Entrepôt de données -MySQL**
   - 5.1 Présentation de MySQL
   - 5.2 Tables de Dimension
   - 5.3 Tables de Faits
   - 5.4 Relations et Contraintes
6. **Analyse et Visualisation avec Power BI**
   - 6.1 Connexion et Modèle de données
   - 6.2 Pages du Dashboard
   - 6.3 Mesures DAX
7. **Résultats et Analyse des données**
   - 7.1 Statistiques générales du tournoi
   - 7.2 Analyse des équipes
   - 7.3 Analyse des joueurs
   - 7.4 Analyse des stades
8. **Conclusion et Perspectives**
   - 8.1 Bilan du projet
   - 8.2 Difficultes rencontrées
   - 8.3 Perspectives d'amélioration
9. **Bibliographie**

1. Introduction au Projet

1.1 - Contexte et Objectifs

La Coupe d'Afrique des Nations (AFCON) 2025 a ete organisee au Maroc, du 21 decembre 2025 au 18 janvier 2026. Cette edition a reuni 24 equipes nationales africaines reparties en 6 groupes, pour un total de 52 matchs disputes dans 8 stades a travers le Royaume du Maroc.

Ce projet a pour objectif de construire un systeme decisionnel complet (Business Intelligence) autour de cette competition. Il couvre l'ensemble de la chaine BI : collecte des donnees, modelisation d'un entrepot, integration ETL et visualisation interactive. Le projet est realise dans le cadre de la formation Developpement des Systemes d'Information .

1.2 - Perimetre du Projet

Indicateur	Valeur
Competition	AFCON 2025 - Maroc
Periode	21 decembre 2025 - 18 janvier 2026
Nombre de matchs	52 matchs (phase de groupes + phase finale)
Equipes participantes	24 equipes nationales (CAF)
Joueurs references	555 joueurs
Stades	8 stades marocains
Tables de donnees	7 tables (4 dimensions + 3 faits)
Metriques par match	Plus de 40 colonnes statistiques

1.3 - Technologies Utilisees

Le projet repose sur trois outils principaux complementaires :

Technologie	Version	Role
MySQL	8.0.44	Base de données : stockage de l'entrepot
Talend Open Studio	Version open source	Outil ETL : extraction, transformation, chargement
Microsoft Power BI	Desktop 2025	Visualisation : tableaux de bord interactifs
Fichiers CSV	—	Sources de données brutes (dataSets)
SQL / DAX	Standard	Langages de requete et de calcul

2. Sources de Données : Collecte et Préparation

2.1 - Méthode de Collecte des Données

La collecte des données statistiques de football est une étape fondamentale dans tout projet BI sportif. Plusieurs approches sont possibles selon les sources disponibles et les droits d'accès.

2.1.1 - Scraping Web

Le scraping (ou extraction web) consiste a extraire automatiquement des données depuis des sites web spécialises dans les statistiques footballistiques.

Pour l'AFCON 2025, les principales sources consultables sont :

- FootyStats.org : plateforme specialisee proposant des statistiques detaillees (xG, possession, tirs, corners, cartons, cotes de paris) pour plus de 100 competitions mondiales.
- FBref.com (Sports Reference) : base de données football avec historiques detailles de joueurs, equipes et competitions africaines.
- SofaScore.com : agregateur de scores en temps reel avec API accessible pour les developeurs.
- Transfermarkt.com — données sur les joueurs, valeurs marchandes et historiques de clubs.
- API-Football (RapidAPI) — API REST professionnelle fournissant des données en temps reel sur plus de 600 competitions.

Le processus de scraping utilise generalement des extensions (exemple : « Data scraper » dans chrome) ou just pandas en Python :

```
# Exemple de scraping avec Python
import requests
from bs4 import BeautifulSoup
import pandas as pd

url = 'https://footystats.org/africa/africa-cup-of-nations'
response = requests.get(url, headers={'User-Agent': 'Mozilla/5.0'})
soup = BeautifulSoup(response.content, 'html.parser')
# Extraction des tableaux de statistiques
tables = soup.find_all('table', class_='stats-table')
df = pd.read_html(str(tables[0]))[0]
df.to_csv('matches_afcon2025.csv', index=False)
```

2.1.2 - Telechargement Direct (CSV)

Dans notre projet, les données ont été obtenues directement en format CSV depuis la plateforme FootyStats.org. Cette approche est plus rapide et plus fiable que le scraping manuel, car la plateforme met a disposition des exports structures et nettoyes pour chaque competition.

Avantages du téléchargement direct par rapport au scraping :

- Données déjà structurees en colonnes , moins de traitement necessaire.
- Moins de risque de blocage ou de CAPTCHA.
- Historique complet disponible en un seul fichier.
- Format CSV directement lisible par Talend.

2.2 - Description des Fichiers CSV Sources

Fichier CSV	Lignes	Contenu
matches-2025-stats.csv	52	Scores, buts, corners, cartons, possession, tirs, xG, affluence, cotes
players-2025-stats.csv	555	Nom, age, position, club, nationalite, minutes jouees
teams-2025-stats.csv	24	Statistiques collectives des equipes
league-2025-stats.csv	2	Statistiques globales de la competition

Exemple of colonnes cles utilisees dans le projet:

Colonne source	Table cible	Description
home/away_team_name	fact_matches	Equipes (resolu en FK via lookup)
home_team_goal_count	home_goals	Buts marques par l'equipe domicile
total_goal_count	total_goals	Total buts du match
attendance	attendance	Affluence du stade
home_team_possession	home_possession	Possession en pourcentage
team_a_xg / team_b_xg	xg_home / xg_away	Expected Goals : buts attendus
full_name	player_name	Nom complet du joueur
position	position	Poste (GK, Defender, Midfielder, Forward)
age	age	Age du joueur

2.3 - Qualité et Nettoyage des données

Plusieurs problemes de qualite ont ete identifies et traites lors de la préparation :

- **Filtrage via tFilterRow : exclusion des lignes sans nom** Valeurs nulles dans les noms de joueurs .
- **Contrainte UNIQUE KEY sur team_name dans MySQL** Doublons dans dim_team :
- **Standardisation via tMap : conversion au format DATE MySQL** Formats de dates heterogenes (CSV) .
- **Table de correspondance manuelle et normalisation dans tMap**Noms de stades incoherents entre CSV et BDD .
- **Configuration UTF-8MB4 dans MySQL et Talend** Encodage caracteres speciaux .

3. Architecture et Méthodologie ETL

3.1 Vue d'ensemble de l'Architecture

L'architecture suit le modele classique d'un systeme decisionnel en trois couches :

Couche	Composant	Description
Source (dataSets)	Fichiers CSV	4 fichiers statistiques AFCON 2025 (FootyStats)
Integration ETL	Talend Open Studio	7 jobs : extraction, transformation, chargement
Stockage (DW)	MySQL 8.0	Base africa_cup_dw : modèle en etoile
Presentation (visualisation)	Power BI Desktop	8 pages de tableaux de bord interactifs

3.2 - Méthodologie ETL

Le processus ETL (Extract, Transform, Load) est le coeur du pipeline de données. Il garantit le transfert fiable et reproductible des données brutes vers l'entrepot structure. Voici le detail de chaque phase :

3.2.1 - Phase E : Extraction

L'extraction consiste a lire les fichiers CSV sources et a les amener dans l'environnement de traitement Talend, lors de cette phase :

- Le composant tFileInputDelimited lit les fichiers CSV ligne par ligne en respectant le separateur (virgule) et l'encodage UTF-8.
- Un schema de metadonnées est defini dans Talend pour chaque fichier source (nom des colonnes, types de donnees, longueurs).
- Les fichiers sont stockes localement dans le repertoire du projet Talend, dans la section Metadata > File delimited.
- Pour les fichiers volumineux (comme players avec 555 lignes et plus de 60 colonnes), le composant gere automatiquement la memoire.

3.2.2 Phase T : Transformation

La transformation est la phase la plus complexe ,Elle inclut plusieurs operations :

- Mapping de colonnes : les colonnes sources (ex: home_team_name) sont mappees vers les colonnes cibles (ex: home_team_id) via le composant tMap.
- Resolution des cles etrangeres (Lookup) : les noms d'equipes, de stades et de joueurs sont traduits en identifiants numeriques (FK) via des jointures avec les tables de dimension deja chargees dans MySQL (tDBInput).
- Filtrage : le composant tFilterRow elimine les lignes invalides (noms vides, valeurs aberrantes).
- Calcul de nouvelles colonnes : certains champs derives (total_goals = home_goals + away_goals) sont calcules directement dans tMap.
- Conversion de types : les dates au format texte sont converties en type DATE MySQL. Les pourcentages sont convertis en DECIMAL(5,2).
- Tri : le composant tSortRow trie les enregistrements de dim_date par ordre chronologique avant insertion.

3.2.3 - Phase L : Chargement

Le chargement consiste a inserer les données transformées dans les tables MySQL de l'entrepôt :

- Le composant tDBOutput insere les enregistrements dans la table cible. Le mode INSERT est utilise (les tables sont videes avant chaque chargement complet).
- Les contraintes d'integrite referentielle (FOREIGN KEY) sont verifiees par MySQL lors de l'insertion — tout enregistrement avec une FK invalide est rejete.
- Un composant tLogRow intercepte les enregistrements rejetes et les affiche dans la console Talend pour audit.
- L'ordre de chargement est critique : les tables de dimension doivent etre chargees avant les tables de faits (pour respecter les contraintes FK).

Ordre d'execution recommande :

```
1. JOB_01_DIM_DATE       ➔  dim_date
2. JOB_02_DIM_TEAM       ➔  dim_team
3. JOB_04_DIM_STADIUM    ➔  dim_stadium
4. JOB_03_DIM_PLAYER     ➔  dim_player
5. JOB_05_FACT_MATCHES   ➔  fact_matches
6. JOB_06_FACT_PLAYERS   ➔  fact_player_stats
7. load_fact_league_stats ➔  fact_league_stats
```

3.3 Modèle en Etoile (Star Schéma)

Le schema en etoile est constitue de 4 tables de dimension et 3 tables de faits, toutes stockees dans la base africa_cup_dw :

Type	Table	Cle Primaire	Description
Dimension	dim_date	date_id	Calendrier du tournoi
Dimension	dim_team	team_id	Les 24 equipes nationales
Dimension	dim_player	player_id	Les 555 joueurs
Dimension	dim_stadium	stadium_id	Les 8 stades marocains
Table Fait	fact_matches	match_id	Statistiques des 52 matchs
Table Fait	fact_player_stats	stat_id	Performances individuelles
Table Fait	fact_league_stats	stat_id	Statistiques globales

4. Integration ETL avec Talend Open Studio

4.1 - Présentation de Talend Open Studio

Talend Open Studio for Data Integration est un outil ETL open source permettant de concevoir des pipelines de données graphiques. Chaque job est compose de composants relies par des flux de données (Main, Lookup, Reject). Les composants principaux utilises sont :

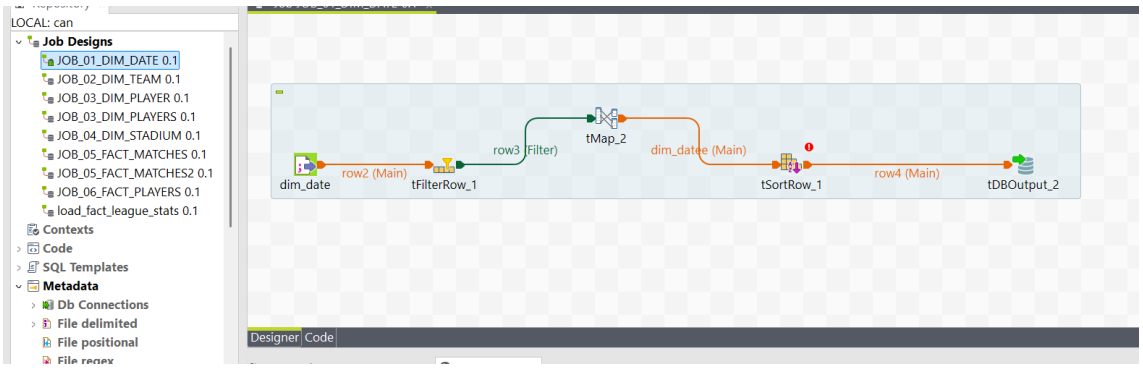
Composant Talend	Rôle
tFileInputDelimited	Lecture d'un fichier CSV avec separateur virgule ou point-virgule
tMap	Transformation centrale : mapping, jointures (lookup), calculs, filtres
tDBInput	Lecture d'une table MySQL — source de lookup
tDBOutput	Ecriture (INSERT/UPDATE) dans une table MySQL
tFilterRow	Filtrage des lignes selon une condition (ex: nom != null)
tLogRow	Affichage dans la console — audit et debug
tSortRow	Tri des enregistrements avant insertion

L'espace de travail du projet (LOCAL: can) contient 9 Job Designs avec les metadonnées des connexions de base de données et des fichiers delimites.

4.2 – Jobs ETL : Tables de Dimensions

Job	Table cible	Composants principaux
JOB_01_DIM_DATE	dim_date	tFileInput -> tFilterRow -> tMap -> tSortRow -> tDBOutput
JOB_02_DIM_TEAM	dim_team	tFileInput -> tMap -> tDBOutput
JOB_03_DIM_PLAYER	dim_player	tFileInput -> tMap + tDBInput(lookup dim_team) -> tDBOutput
JOB_03_DIM_PLAYERS	dim_player	Variante avec tLogRow pour gestion des erreurs
JOB_04_DIM_STADIUM	dim_stadium	tFileInput -> tMap -> tLogRow -> tDBOutput

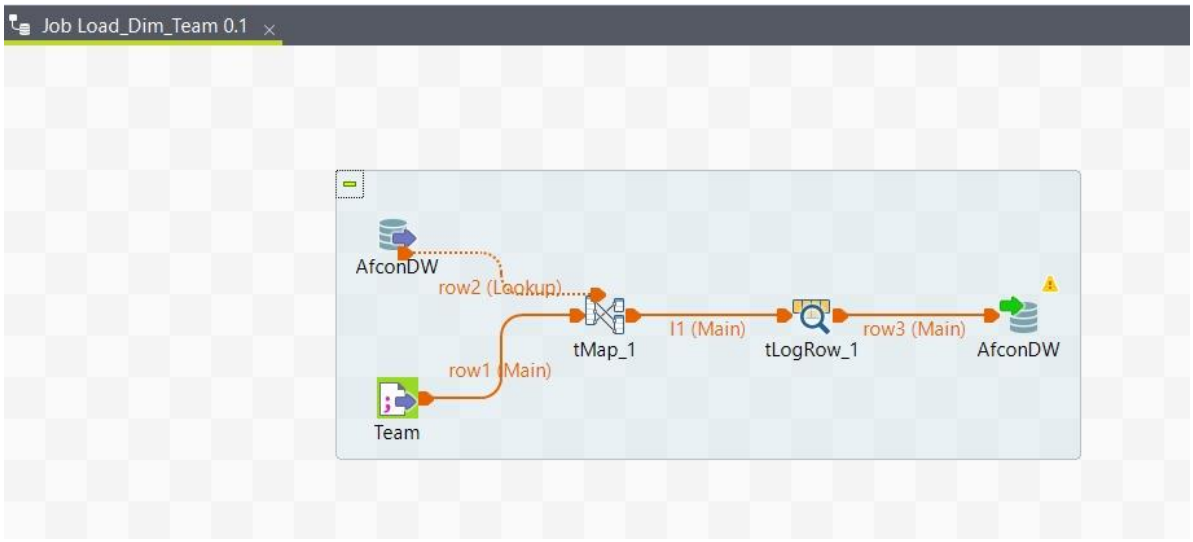
JOB_01_DIM_DATE :



Ce job généré les enregistrements temporels pour la periode du tournoi (21 decembre 2025 - 18 janvier 2026). Le flux est le suivant :

- dim_date (source CSV) : lecture du fichier des dates via tFileInputDelimited avec schema defini dans les metadonnées Talend.
- tFilterRow_1 : filtre les lignes dont la date est hors de la periode du tournoi ou dont les champs obligatoires sont vides.
- tMap_2 : transformation et enrichissement — calcul du champ day_of_week (jour de la semaine numerique), du champ day_name (nom du jour), du champ is_weekend (booleen : 1 si samedi ou dimanche), et du champ month_name.
- tSortRow_1 : tri chronologique ascendant par full_date avant insertion pour garantir la coherence des date_id.
- tDBOutput_2 : insertion finale dans la table dim_date de MySQL avec le mode INSERT et validation de la cle primaire date_id.

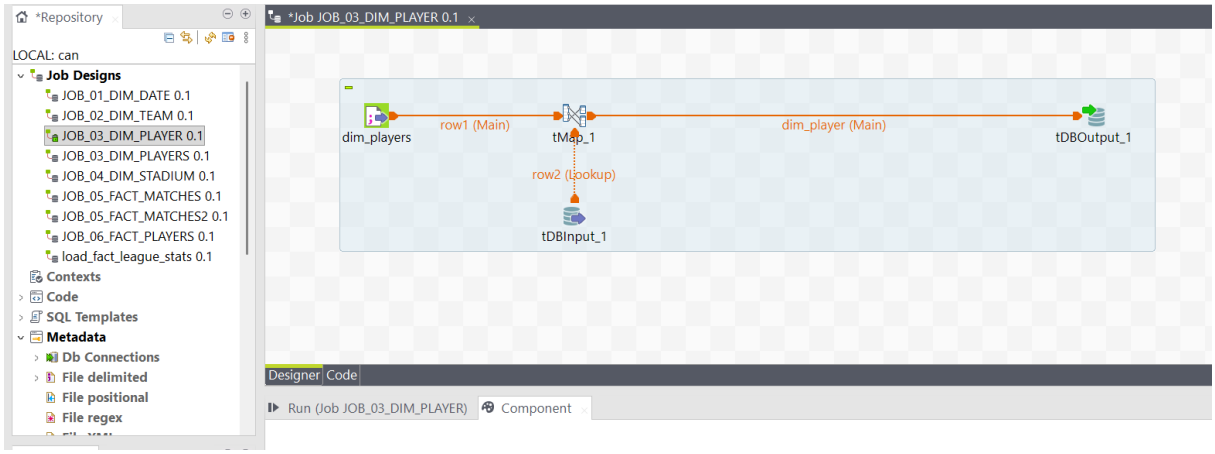
JOB_02_DIM_TEAM



Ce job est le plus simple du projet. Il charge les 24 equipes nationales directement depuis le fichier CSV sans lookup. Le flux : dim_Team (CSV) -> tMap -> tDBOutput.

- tFileInputDelimited lit le fichier dim_Team.csv contenant les colonnes : team_name, group_name, confederation, fifa_ranking, team_code.
- tMap effectue uniquement le mapping direct des colonnes sources vers les colonnes cibles de dim_team, sans transformation complexe.
- tDBOutput insere les 24 lignes dans dim_team. La contrainte UNIQUE KEY sur team_name protege contre les doublons si le job est reexecute.

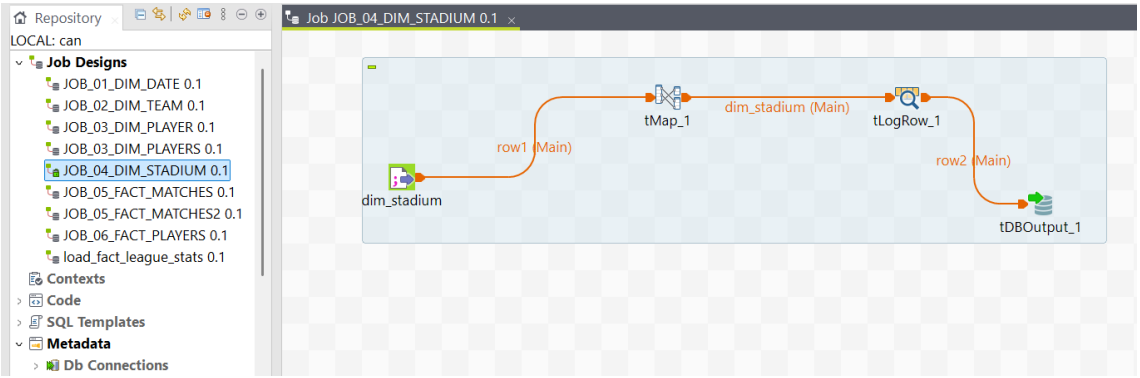
JOB_03_DIM_PLAYER :



Ce job est plus complexe car il doit resoudre la cle etrangere team_id pour chaque joueur. Le fichier source contient le nom de l'equipe mais pas son identifiant MySQL.

- dim_players (source CSV) : lecture du fichier players-2025-stats.csv via tFileInputDelimited (555 lignes, colonnes : full_name, age, position, nationality, current_club, plus le nom de l'equipe nationale).
- tMap_1 : composant central avec deux flux entrants. Le flux principal (row1 Main) porte les données du joueur. Le flux secondaire (row2 Lookup) provient de tDBInput_1 qui lit la table dim_team deja chargee dans MySQL.
- La jointure dans tMap fait correspondre le nom de l'equipe du CSV avec team_name dans dim_team pour recuperer le team_id correspondant.
- dim_player (Main) : flux de sortie principal envoye vers tDBOutput_1 pour insertion dans la table dim_player de MySQL.

JOB_04_DIM_STADIUM :



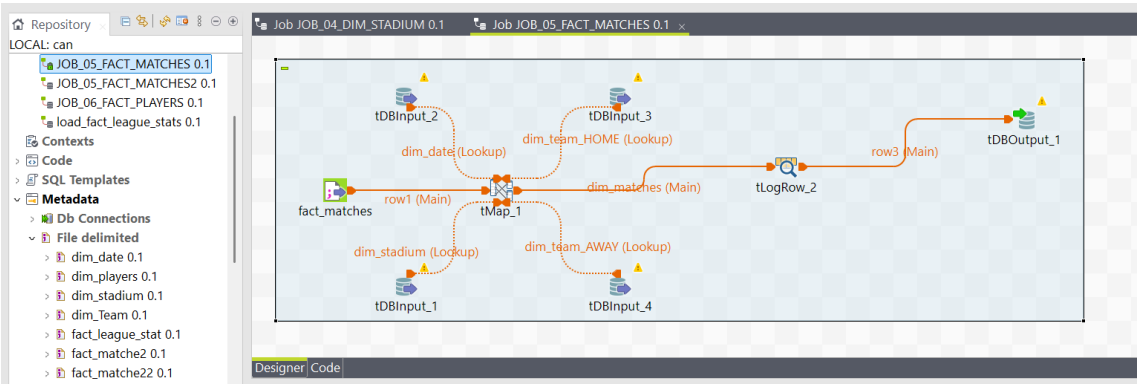
Ce job charge les 8 stades marocains. Le flux est simple : dim_stadium (CSV) ➔ tMap_1 ➔ tLogRow_1 ➔ tDBOutput_1.

- tFileInputDelimited lit les colonnes : stadium_name, city, capacity, latitude, longitude.
- tMap_1 effectue le mapping direct sans lookup (pas de cle etrangere a resoudre pour les stades).
- tLogRow_1 : audit intermediaire - affiche chaque stade charge pour verification visuelle en console.
- tDBOutput_1 : insertion dans dim_stadium. Ce job doit imperativement s'executer avant les jobs de faits qui referencent stadium_id.

4.3 - Jobs ETL : Tables de Faits

Job	Table cible	Lookups necessaires
JOB_05_FACT_MATCHES	fact_matches	4 lookups : dim_date, dim_team x2 (home/away), dim_stadium
JOB_06_FACT_PLAYERS	fact_player_stats	3 lookups : dim_player, dim_team, dim_stadium
load_fact_league_stats	fact_league_stats	Chargement direct sans lookup

JOB_05_FACT_MATCHES :

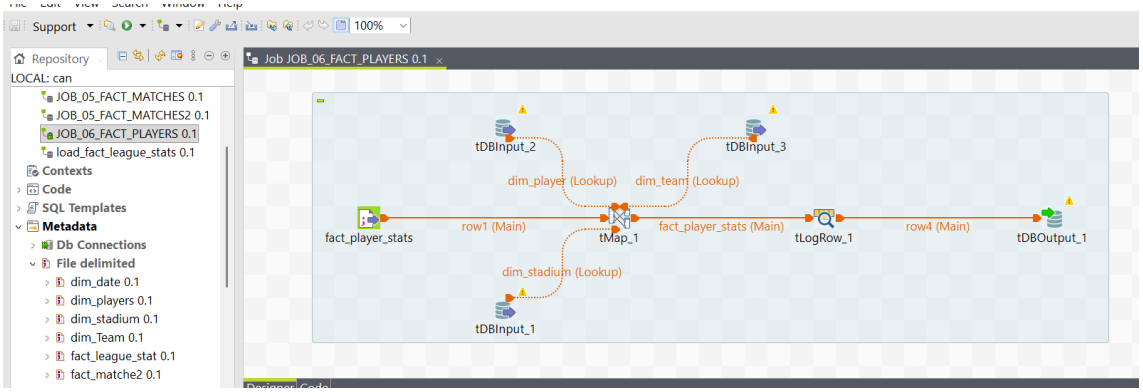


Ce job est le plus complexe du projet. Il charge les statistiques des 52 matchs en résolvant simultanement 4 cles etrangeres. La source est le fichier fact_matches.csv (plus de 60 colonnes).

- fact_matches (CSV) : source principale lue par tFileInputDelimited avec le schema complet des colonnes de matchs.
- tDBInput_2 (dim_date Lookup) : lit la table dim_date depuis MySQL. Dans tMap, la date du match (au format texte) est convertie et associee a date_id.
- tDBInput_3 (dim_team_HOME Lookup) : lit dim_team pour resoudre l'equipe domicile , Le champ home_team_name du CSV est associe a team_id pour produire home_team_id.
- tDBInput_4 (dim_team_AWAY Lookup) : seconde lecture de dim_team pour l'equipe visiteur. Produit away_team_id independamment.
- tDBInput_1 (dim_stadium Lookup) : lit dim_stadium pour resoudre stadium_name vers stadium_id.

- tMap_1 : orchestration centrale de tous les lookups. Chaque flux entrant est mis en correspondance avec le flux principal. Les colonnes numeriques (tirs, buts, cartons) sont castees en INT, les possessions en DECIMAL(5,2).
- tLogRow_2 : journalisation des enregistrements transformes pour audit avant insertion.
- tDBOutput_1 : insertion des 52 lignes dans fact_matches avec validation de toutes les FK par MySQL.

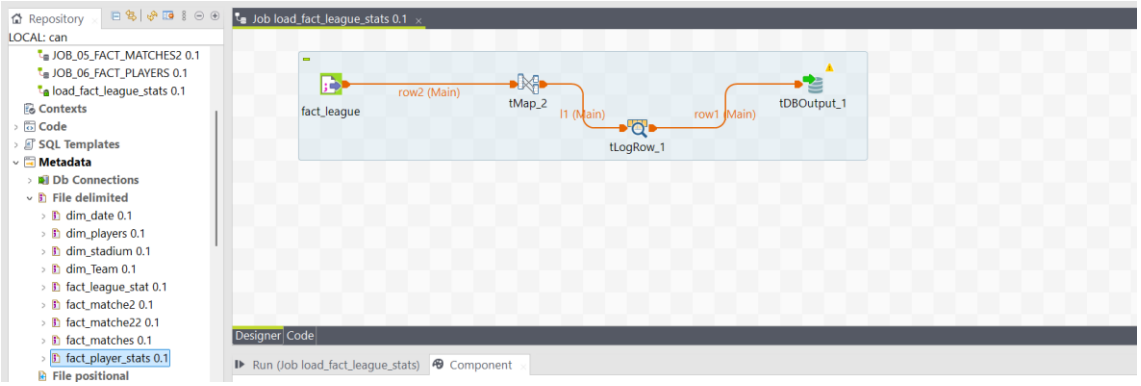
JOB_06_FACT_PLAYERS :



Ce job charge les 555 statistiques individuelles des joueurs avec 3 lookups simultanes.

- fact_player_stats (CSV) : source principale contenant les statistiques par joueur (goals, assists, minutes, shots, cards, passes, rating).
- tDBInput_2 (dim_player Lookup) : lit dim_player depuis MySQL pour resoudre player_name vers player_id.
- tDBInput_3 (dim_team Lookup) : resout team_name vers team_id pour identifier l'equipe nationale du joueur.
- tDBInput_1 (dim_stadium Lookup) : resout stadium_name vers stadium_id pour associer le joueur au stade du match.
- tMap_1 : jointures et transformations — calcul du champ pass_accuracy (passes_completed / total_passes * 100), validation du champ rating (arrondi a 2 decimales).
- tLogRow_1 : audit des enregistrements transformes.
- tDBOutput_1 : insertion dans fact_player_stats avec validation des cles etrangere

load_fact_league_stats :



Ce job est le plus simple des jobs de faits. Il charge les statistiques globales de la competition (1 ligne par equipe dans le fichier league-2025-stats.csv).

- fact_league (CSV) ➔ tMap_2 : mapping direct des statistiques globales (moyenne buts, moyenne corners, moyenne cartons par match).
- tLogRow_1 : affichage de chaque ligne pour verification.
- tDBOutput_1 : insertion dans fact_league_stats.

4.4 - Gestion des Erreurs :

Chaque job integre un composant tLogRow pour intercepter les enregistrements problematiques.,Pour le job JOB_03_DIM_PLAYERS, deux flux d'erreur (tLogRow_1 et tLogRow_2) capturent les joueurs sans correspondance dans dim_team, Ces logs sont consultables dans la console Talend après chaque execution.

Et le grand problème de talend que ne sa affiche jamais ou exacte errer existe.

5. Conception de l'Entrepôt de Données : MySQL

5.1 Présentation de MySQL

MySQL est un système de gestion de base de données relationnelle (SGBDR) open source, développé par Oracle. C'est l'un des SGBDR les plus utilises au monde, notamment pour les applications web et les systèmes d'information.

Voici ses caracteristiques:

Caracteristique	Detail
Version utilisee	MySQL 8.0.44 (Windows 64-bit)
Moteur de stockage	InnoDB - supporte les transactions ACID et les clés etrangeres
Acces	localhost (127.0.0.1) - port 3306
Outil d'administration	MySQL Workbench
Base de donnees	africa_cup_dw
Nombre de tables	7 tables (4 dimensions + 3 faits)

MySQL a été choisi pour sa fiabilite, sa compatibilite avec Talend (connecteur JDBC natif) et sa facilite d'integration avec Power BI (connecteur officiel MySQL Database)

5.2 - Tables de Dimension

5.2.1 - dim_team : Equipes Nationales

Cette table reference les 24 equipes participantes avec leur groupe de competition et leur classement FIFA.

Colonne	Type	Description
team_id	INT PK AUTO_INCREMENT	Identifiant unique
team_name	VARCHAR(100) UNIQUE	Nom officiel de l'equipe
group_name	VARCHAR(10)	Groupe (A a F)
confederation	VARCHAR(50)	Confederation (CAF)
fifa_ranking	INT	Classement FIFA au moment du tournoi
team_code	VARCHAR(10)	Code court (MAR, SEN, EGY...)

5.2.2 dim_player : Joueurs

Colonne	Type	Description
player_id	INT PK	Identifiant unique (1 a 555)
player_name	VARCHAR(150)	Nom complet du joueur
position	VARCHAR(50)	Poste : Goalkeeper / Defender / Midfielder / Forward
age	INT	Age (moyenne : 28,4 ans)
nationality	VARCHAR(100)	Pays de nationalite
current_club	VARCHAR(100)	Club actuel
team_id	INT FK	Reference vers dim_team

5.2.3 - dim_stadium : Stades

Stade	Ville	Capacite	longitude &latitude
Complexe Sportif Prince Moulay Abdellah	Rabat	69 500	_
Grand Stade de Tanger	Tanger	68 000	
Stade Mohammed V	Casablanca	67 000	
Grand Stade d'Agadir	Agadir	45 480	
Complexe Sportif de Fes	Fes	45 000	
Grand Stade de Marrakech	Marrakech	45 240	
Complexe Sportif Prince Heritier	Rabat	22 000	
Stade Annexe Olympique PMA	Rabat	21 000	

5.2.4 - dim_date : Calendrier

Table de dimension temporelle couvrant la periode du 21 decembre 2025 au 18 janvier 2026. Colonnes : date_id, full_date, day, month, year, day_name, day_of_week, month_name, is_weekend. Elle permet des analyses temporelles (semaine / week-end, evolution des performances).

5.3 - Tables de Faits

5.3.1 - fact_matches : Statistiques de Matchs

Table centrale de 52 enregistrements avec 26 metriques analytiques par match.

Colonne	Type	Description
match_id	INT PK	Identifiant du match
date_id / home_team_id / away_team_id / stadium_id	INT FK	Cles etrangeres vers les dimensions
tournament_phase	VARCHAR(50)	Phase : Group Stage, Quarter-Finals, Semi-Finals, Final
home_goals / away_goals / total_goals	INT	Nombre de buts
home/away_corners	INT	Corners par equipe
home/away_yellow_cards / red_cards	INT	Cartons disciplinaires
home/away_possession	DECIMAL(5,2)	Possession (%)
home/away_shots / shots_on_target	INT	Tirs totaux et tirs cadres
xg_home / xg_away	DECIMAL(5,2)	Expected Goals
attendance	INT	Affluence (spectateurs)

5.3.2 - fact_player_stats: Performances Individuelles

555 enregistrements de statistiques individuelles par joueur. Colonnes principales : stat_id, player_id (FK), team_id (FK), date_id (FK), position_played, minutes_played, goals, assists, shots, shots_on_target, yellow_cards, red_cards, passes_completed, pass_accuracy, rating.

5.4 - Relations et Contraintes

L'integrite referentielle est assuree par des contraintes FOREIGN KEY avec le moteur InnoDB :

- fact_matches.date_id ← → dim_date.date_id
- fact_matches.home_team_id ← → dim_team.team_id
- fact_matches.away_team_id ← → dim_team.team_id (relation multiple)
- fact_matches.stadium_id ← → dim_stadium.stadium_id
- fact_player_stats.player_id ← → dim_player.player_id
- fact_player_stats.team_id ← → dim_team.team_id
- fact_player_stats.date_id ← → dim_date.date_id
- dim_player.team_id ← → dim_team.team_id

6. Analyse et Visualisation avec Power BI

6.1- Connexion et Modèle de données

Power BI Desktop se connecte a MySQL via le connecteur natif MySQL Database. Les 7 tables sont importees en mode Import (chargement en memoire). Les relations sont definies dans l'editeur de modele pour reproduire le schema en etoile defini dans l'entrepot.

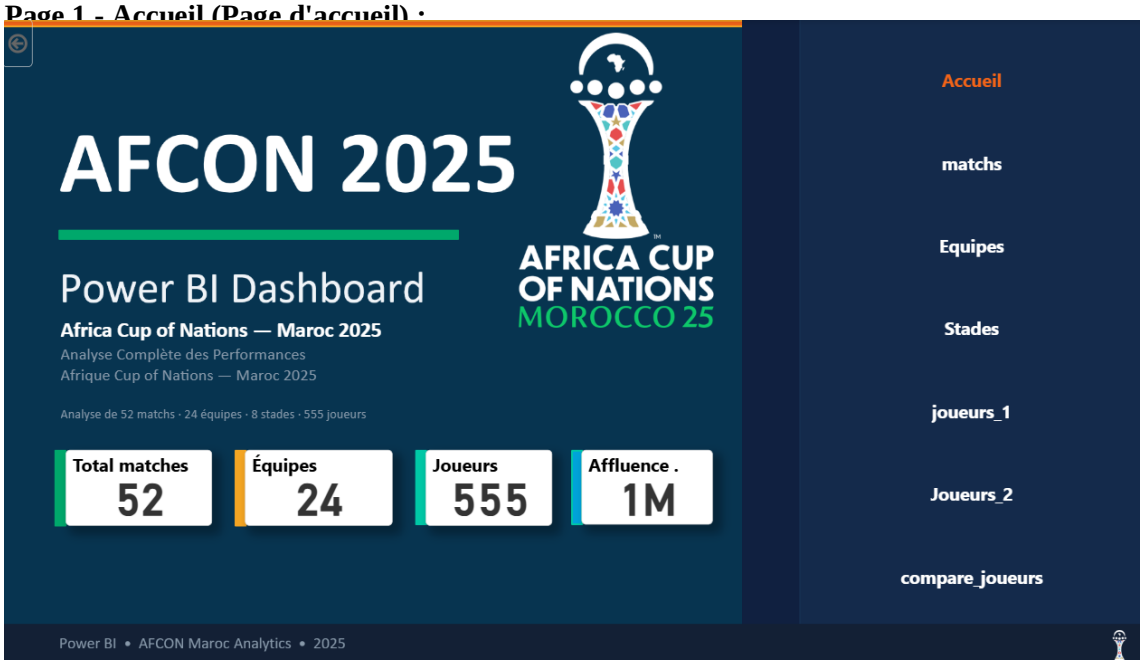
Relations configurees dans Power BI :

- dim_player ← → fact_player_stats (player_id)
- dim_team ← → fact_matches (home_team_id + away_team_id)
- dim_stadium ← → fact_matches (stadium_id)
- dim_date ← → fact_matches (date_id)
- dim_date ← → fact_player_stats (date_id)
- dim_team ← → fact_league_stats (team_id)

6.2 - Description des Pages du Dashboard

Le tableau de bord Power BI est compose de 8 pages interactives. Chaque page possede une barre de navigation en haut permettant de passer d'une page a l'autre. Ci-dessous la description detaillee de chaque page (les captures d'ecran correspondantes sont a inserer au-dessus de chaque description) :

Page 1 - Accueil (Page d'accueil) :



Cette page constitue la page d'entree du tableau de bord. Elle offre une vue d'ensemble globale de la competition AFCON 2025.

Visuels presents :

- Titre principal : "AFCON 2025 : Power BI Dashboard" avec le logo officiel de la competition.
- 4 cartes KPI : Total Matches (52), Equipes (24), Joueurs (555), Affluence totale (~1M).
- Barre de navigation verticale (droite) : boutons cliquables vers les 7 autres pages (matchs, Equipe, Stades, joueur, Joueurs, fact_player, Page 4).
- Description : "Analyse Complete des Performances : Afrique Cup of Nations - Maroc 2025".

Page 2 : Matchs (Statistiques des Matchs) :

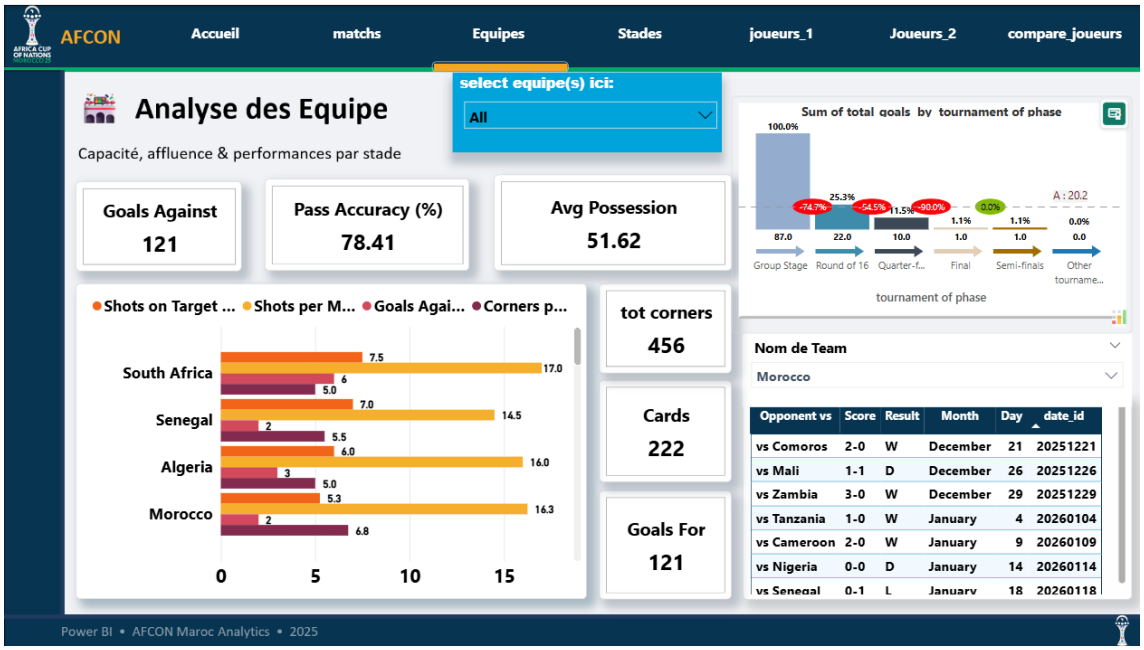


Cette page analyse les performances collectives lors des matchs du tournoi. Elle utilise les tables de mesures Intervalles10 et Intervalles15 pour le decoupage temporel.

Visuels presents :

- 3 cartes KPI en haut : Total Attendance (plus de 1,3M), Moyen Buts/Match (2.33), Total Buts (121).
- Graphique lineaire "Buts par Intervalle de 10 Minutes" : montre la distribution des buts par tranche de 10 minutes (0-10, 11-20, ... 81-90). Pic visible entre 41-50 et 81-90.
- Graphique lineaire "Buts par Intervalle de 15 Minutes" : meme analyse par tranches de 15 minutes (0-15, 16-30, ..., 76-90) pour le progression croissante en fin de match.
- Jauge circulaire "BTTS Percentage" (Both Teams To Score) : valeur 46.00% pour indique que dans 46% des matchs, les deux equipes ont marque.
- Graphique Radar : axes Valeur Goals, Valeur Shots, Valeur Rating, Valeur Assists pour comparaison par categorie.
- Graphique donut "Buts 1ere MT et Buts 2eme MT" : repartition des buts par mi-temps (plus de buts en 2eme MT).

Page 3 : Equipe (Analyse des Equipes) :

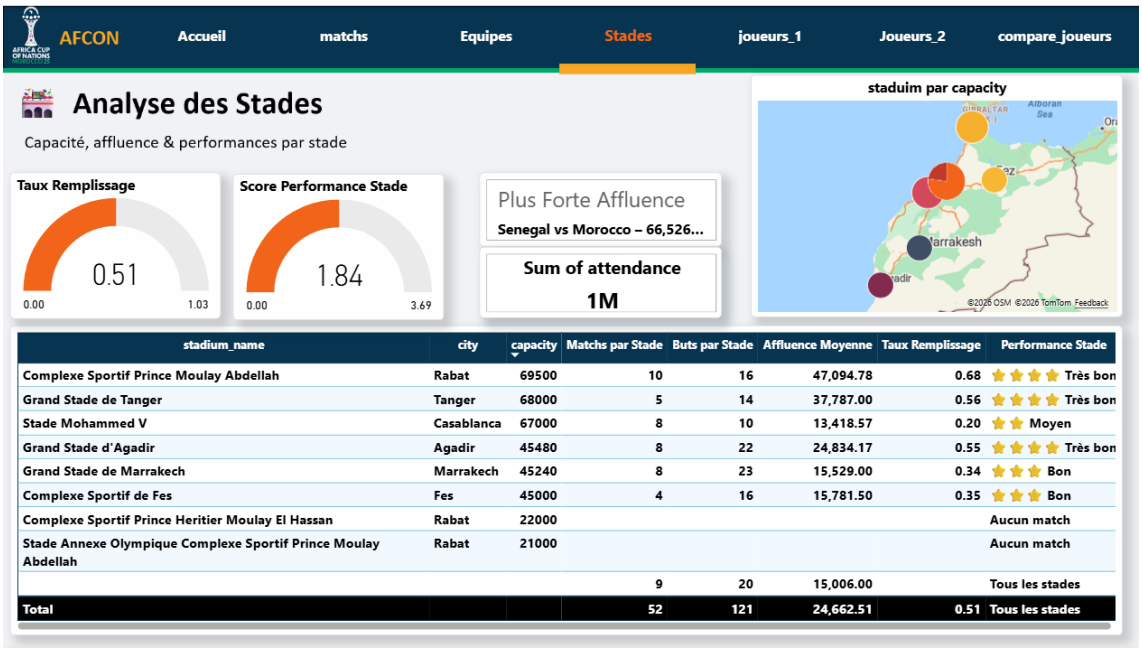


Cette page permet l'analyse detaillee par equipe grace a un selecteur interactif. Elle utilise la table de mesures Team Matches Clean.

Visuels presents :

- Selecteur "Team Selector" : liste deroulante permettant de filtrer toutes les visualisations sur une equipe specifique (exemple : Cameroon).
- 5 cartes KPI : Pass Accuracy % (78.41), Total Corners (456), Goals Against (121), Avg Possession (51.62), Cards (222), Goals For (121).
- Graphique en barres horizontales : Shots on Target per Match, Shots per Match, Goals Against, Corners per Match — comparaison entre equipes.
- Graphique en cascade (waterfall) "Sum of total goals by tournament of phase" : decompose les buts par phase (Group Stage, Round of 16, Quarter-finals, Semi-finals, Final) avec variations en rouge/vert.
- Table historique des matchs par equipe : colonnes Opponent vs, Score, Result (W/D/L), Month, Day, date_id - permet de voir tous les matchs joues.

Page 4 - Stades (Analyse des Stades) :



stadium_name	city	capacity	Matchs par Stade	Buts par Stade	Affluence Moyenne	Taux Remplissage	Performance Stade
Complexe Sportif Prince Moulay Abdellah	Rabat	69500	10	16	47,094.78	0.68	Très bon
Grand Stade de Tanger	Tanger	68000	5	14	37,787.00	0.56	Très bon
Stade Mohammed V	Casablanca	67000	8	10	13,418.57	0.20	Moyen
Grand Stade d'Agadir	Agadir	45480	8	22	24,834.17	0.55	Très bon
Grand Stade de Marrakech	Marrakech	45240	8	23	15,529.00	0.34	Bon
Complexe Sportif de Fes	Fes	45000	4	16	15,781.50	0.35	Bon
Complexe Sportif Prince Heritier Moulay El Hassan	Rabat	22000					Aucun match
Stade Annexe Olympique Complexe Sportif Prince Moulay Abdellah	Rabat	21000					Aucun match
			9	20	15,006.00		Tous les stades
Total			52	121	24,662.51	0.51	Tous les stades

Cette page offre une analyse complete des 8 stades marocains, incluant leur taux de remplissage, affluence et performance globale. Elle utilise les mesures de la table dim_stadium.

Visuels presents :

- 2 jauges KPI : Taux Remplissage (0.51) et Score Performance Stade (1.84) — avec echelles de 0 a 1.03 et 0 a 3.69.
- 2 cartes : Plus Forte Affluence (Senegal vs Morocco - 66,526) et Sum of Attendance total (1M).
- Carte geographique du Maroc : localisation des 8 stades avec bulles proportionnelles a la capacite ("stadium par capacity"). Les stades sont positionnes sur Rabat, Casablanca, Tanger, Agadir, Fes, Marrakech.
- Tableau detaille des stades : colonnes stadium_name, city, capacity, Matchs par Stade, Buts par Stade, Affluence Moyenne, Taux Remplissage, Performance Stade (etoiles + label : Tres bon / Bon / Moyen).
- Ligne totale : 52 matchs, 121 buts, affluence moyenne 24,662.51, taux global 0.51.

Page 5 – joueur_1 (Profil des Joueurs) :



Cette page analyse le profil demographique et positional des 555 joueurs de la competition. Elle s'appuie sur les mesures de la table Tranches Age.

Visuels presents :

- 2 cartes KPI : Age Moyen (28.4) et Total Joueurs (555).
- Jauge "Efficacite" : valeur 0.48 pour l efficacite moyenne de tous les joueurs.
- Graphique radar "Radar Passe" : 5 axes (Passes, Precision, Tirs, Buts, Note) pour le profil moyen de contribution des joueurs.
- Graphique donut "Nombre Joueurs by position" : repartition par poste pour le Midfielder (orange), Defender (beige), Forward (rouge), Goalkeeper (bordeaux).
- Graphique en barres horizontales "Age Moyen par position" : Goalkeeper (30), Forward (29), Defender (29), Midfielder (27).
- Graphique en barres horizontales "Age Distribution" par tranches : 18-20 (22), 21-23 (78), 24-26 (130), 27-29 (131), 30-32 (114), 33-35 (50), 36+ (30). La tranche 27-29 est la plus representee.

Page 6 - Joueurs (Statistiques Avancees des Joueurs) :

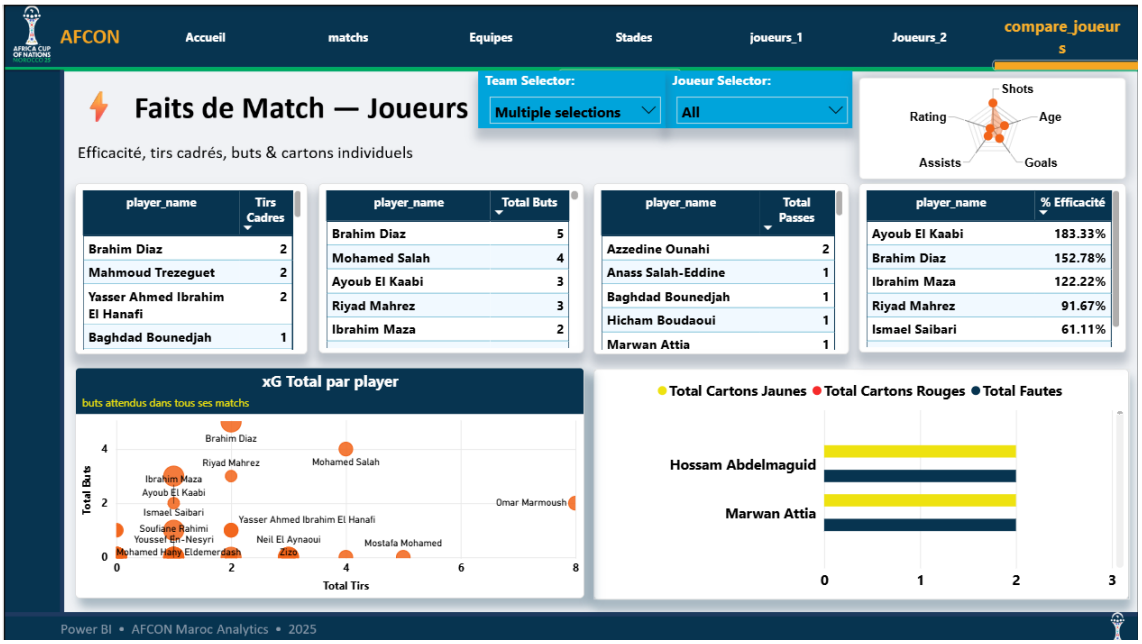


Cette page presente les classements et performances avancees individuelles des joueurs. Elle utilise les mesures globales de performance.

Visuels presents :

- 4 cartes KPI : Nombre Joueurs (555), Total Buts (121), Total Cartons Rouges (9), Total Yellow Cards (206).
- Graphique Radar global (haut droite) : 5 axes avvec Buts Moyen (2.32), Moyenne Note (6.64), Efficacite (0.48), Age Moyen (28.35), Valeur Assists (77.00) .
- Tableau "Top Contributions" : classement par joueur avec Ademola Lookman (7), Sadio Mane (6), Victor Osimhen (6), Brahim Diaz (5), Mohamed Salah (5)...
- Tableau "Top Buteurs" : Brahim Diaz (5), Mohamed Salah (4), Victor Osimhen (4), Ademola Lookman (3), Amad Diallo Traore (3), Ayoub El Kaabi (3)...
- Tableau "Top Passeurs" : Ademola Lookman (4), Sadio Mane (4), Akor Adams (2), Alex Iwobi (2)...
- 2 cartes KPI complementaires : Total Fautes (206) et Total Cards (228).

Page 7 – compare_joueurs (Faits de Match -Joueurs) :



Cette page permet l'analyse individuelle de chaque joueur sur l'ensemble de ses matchs. Deux selecteurs (Team et Joueur) permettent de filtrer dynamiquement toutes les visualisations.

Visuels presents :

- Selecteur "Team Selector" et "Joueur Selector" : filtres en cascade pour choisir une équipe puis un joueur (exemple : maroc , algerie, egypte).
- 3 tableaux KPI cote a cote : Tirs Cadres (Brahim Diaz : 1), Total Buts (Brahim Diaz : 5), Total Passes (ounahi : 2).
- Carte "%GT Efficacite" : kaaabi - 183.33% .
- Graphique radar individuel : 5 axes — Age, Rating, Goals, Shots, Assists .
- Nuage de points "xG Total par player" : axe X = Total Tirs, axe Y = Total Buts — permet d'identifier les joueurs efficaces .
- Graphique en barres horizontales (bas droite) : Total Cartons Jaunes, Total Cartons Rouges, Total Fautes par joueur.

6.3 - Tables de Mesures Crées dans Power BI

En plus des mesures DAX individuelles, plusieurs tables de mesures dediees ont ete creees dans Power BI pour organiser les calculs par theme. Ces tables regroupent les mesures liees et facilitent la maintenance du modele. \

Categories - Table de mesures principales

Contient les mesures de categorisation utilisees dans les graphiques radar et les analyses comparatives. Regroupe les calculs de categories de performances.

Categories Radar - Mesures pour les graphiques Radar

Contient les mesures specifiques aux visualisations de type radar : Valeur Goals, Valeur Assists, Valeur Shots, Valeur Rating, Valeur Normalisee, Valeur Radar. Ces mesures normalisent les valeurs entre 0 et 1 pour permettre une comparaison visuelle multi-axes.

Intervalles10 - Buts par intervalle de 10 minutes

Table de mesures calculant la distribution des buts par tranche de 10 minutes (0-10, 11-20, 21-30, 31-40, 41-50, 51-60, 61-70, 71-80, 81-90). Utilisee dans le graphique lineaire de la page Matchs.

Intervalles15 - Buts par intervalle de 15 minutes

Similaire a Intervalles10 mais avec des tranches de 15 minutes (0-15, 16-30, 31-45, 46-60, 61-75, 76-90). Utilisee dans le second graphique lineaire de la page Matchs pour une lecture complementaire.

Team Matches Clean : Statistiques d'equipe filtrees

Table contenant les mesures calculees par equipe : Pass Accuracy, Total Corners, Goals Against, Goals For, Avg Possession, Total Cards. Utilisee dans la page Equipe avec le selecteur d'equipe interactif.

Tranches Age: Distribution par tranche d'age

Table de mesures creant les tranches d'age pour la distribution des joueurs : 18-20, 21-23, 24-26, 27-29, 30-32, 33-35, 36+. Utilisee dans le graphique Age Distribution de la page joueur.

6.4 - Mesures DAX Individuelles

En complement des tables de mesures, des mesures DAX individuelles ont été crées pour calculer des indicateurs metier non disponibles directement dans les données sources :

Mesure DAX	Table de mesures	Description
%GT Efficacite	Categories Radar	Rapport buts + passes decisives / minutes joues x 90
Total Contributions	Categories	Somme goals + assists par joueur

Mesure DAX	Table de mesures	Description
Score Performance Stade	dim_stadium	Indice composite : buts/match x taux de remplissage
Taux Remplissage	dim_stadium	Affluence moyenne / Capacite du stade
Buts par Stade	dim_stadium	Total buts marques dans chaque stade
Affluence Moyenne	dim_stadium	Moyenne des affluences par stade
Matchs par Stade	dim_stadium	Nombre de matchs joues dans chaque stade
Plus Forte Affluence	dim_stadium	Maximum de l'affluence sur tous les matchs
Classement Stade	dim_stadium	Rang du stade selon le score de performance
BTTS Percentage	Categories	% de matchs avec les deux equipes ayant marque
Valeur Radar	Categories Radar	Mesure normalisee pour les graphiques radar (0-1)
Valeur Goals	Categories Radar	Normalisation du nombre de buts pour le radar
Valeur Assists	Categories Radar	Normalisation des passes decisives pour le radar
Valeur Shots	Categories Radar	Normalisation des tirs pour le radar
Valeur Rating	Categories Radar	Normalisation de la note de performance pour le radar
Valeur Normalisee	Categories Radar	Valeur generique normalisee pour comparaison
Top Joueurs Selectionnes	Categories	Filtre les N meilleurs joueurs pour les tableaux Top
Total Cartons Jaunes	Categories	Somme des cartons jaunes (Total Yellow Cards)
Total Cartons Rouges	Categories	Somme des cartons rouges sur le tournoi (9)
Total Fautes	Categories	Nombre total de fautes commises (206)
Total Passes Completees	Categories	Somme des passes completees par joueur
Valeur_Radar	Categories Radar	Variante de Valeur Radar pour axes specifiques
yellow_cards	Categories	Comptage des cartons jaunes (colonne source)

7. Résultats et Analyse des données

7.1 - Statistiques Générales du Tournois

Indicateur	Valeur	Commentaire
Total matches	52	Phase de groupes + phase finale
Total buts	121	Moyenne de 2,33 buts/match
BTTS (deux equipes marquent)	46%	24 matchs sur 52
Total corners	456	8,77 corners/match en moyenne
Cartons jaunes	228	4,4 jaunes/match
Cartons rouges	9	Tournoi relativement fair-play
Affluence record	66 526	Maroc vs Senegal — Stade Prince Moulay Abdellah
Affluence moyenne	24 662	Taux de remplissage moyen : 51%

7.2 Analyse des Equipes

Exemple avec le Maroc (equipe hote, classe 8e FIFA) :

Indicateur	Maroc
Buts marques	9
Buts encaisses	2
Cartons distribues	10
Precision des passes	85,86 %
Possession moyenne	50,75 %
Corners totaux	456
Resultat final	Elimine en quart de finale

Le Senegal (classe 12e FIFA) est designe vainqueur du tournoi avec la meilleure discipline collective (1 seul carton rouge).

7.3 - Analyse des Joueurs

- Age moyen : 28,4 ans — tranche la plus representee : 27-29 ans (131 joueurs, 23,6%)
- Repartition par poste : Milieux 28% | Defenseurs 27% | Attaquants 25% | Gardiens 20%

- Top buteur : Brahim Diaz — 5 buts, efficacite de 166,67%
- Top contributeurs : Victor Osimhen & Sadio Mane — 6 contributions chacun
- Top passeurs : Ademola Lookman & Sadio Mane — 4 passes decisives chacun

7.4 - Analyse des Stades

Stade	Ville	Matchs	Buts	Affluence moy.	Taux rempl.
Prince Moulay Abdellah	Rabat	10	16	47 094	0,68
Grand Stade Tanger	Tanger	5	14	37 787	0,56
Stade Mohammed V	Casablanca	8	10	13 418	0,20
Grand Stade Agadir	Agadir	8	22	24 834	0,55
Grand Stade Marrakech	Marrakech	8	23	15 529	0,34
Complexe Sportif Fes	Fes	4	16	15 781	0,35

8. Conclusion

8.1 - Synthèse du Travail Réalise

Ce projet de fin d'etudes a ete l'occasion de concevoir et de deployer une solution complete de Business Intelligence autour des données de la Coupe d'Afrique des Nations 2025, organisee au Maroc. Du premier fichier CSV brut jusqu'au tableau de bord Power BI interactif, chaque etape a ete maitrisee et documentée .

Le projet a ete structure autour de trois grandes phases complementaires, chacune s'appuyant sur un outil specialise :

- Phase de modelisation et stockage avec MySQL : conception du schema en etoile africa_cup_dw avec 4 tables de dimension et 3 tables de faits, gestion des contraintes d'integrite referentielle et encodage UTF-8MB4 pour les caracteres speciaux.
- Phase d'integration ETL avec Talend Open Studio : developpement de 9 jobs graphiques realisant l'extraction des fichiers CSV, les transformations (mapping, lookups multiples, conversion de types, filtrage) et le chargement ordonne dans l'entrepot MySQL.
- Phase d'analyse et de visualisation avec Microsoft Power BI : connexion directe a MySQL, définition des relations du modele en etoile, creation de 6 tables de mesures, developpement de 23 mesures DAX et conception de 8 pages de tableaux de bord interactifs.

8.2 - Principaux Résultats Obtenus

L'analyse des données de l'AFCON 2025 a permis de mettre en evidence plusieurs faits marquants :

Domaine	Resultat cle	Source
Tournoi général	121 buts en 52 matchs — moyenne de 2,33 buts/match	fact_matches
Discipline	228 cartons jaunes, 9 rouges — tournoi relativement fair-play	fact_player_stats
Affluence	Record de 66 526 spectateurs (Maroc vs Senegal — Rabat)	fact_matches
Stade le plus rempli	Prince Moulay Abdellah (Rabat) - taux remplissage 0.68	dim_stadium
Meilleur buteur	Brahim Diaz - 5 buts, efficacite individuelle de 100%	fact_player_stats
Top contributeur	Ademola Lookman - 7 contributions (buts + passes)	fact_player_stats
Vainqueur du tournoi	Senegal - meilleure discipline collective (1 seul rouge)	fact_matches
Profil joueurs	Age moyen 28,4 ans - tranche 27-29 ans la plus representee (131)	dim_player
BTTS	46% des matchs avec 2 équipes ayant marque	fact_matches

8.3 - Bilan Technique

Sur le plan technique, ce projet a permis de consolider plusieurs competences importantes :

Compétence	Application dans le projet
Modélisation dimensionnelle	Conception du schema en etoile avec 7 tables : choix des grains et des hiérarchies
ETL avec Talend	9 jobs avec lookups multiples, gestion des erreurs et transformations complexes
SQL / MySQL	Creation de tables, contraintes FK, encodage UTF-8MB4, exports
DAX / Power BI	Plus de 23 mesures DAX, tables de mesures, 7 pages de dashboard interactif
Qualite des données	Filtrage, normalisation des noms, traitement des valeurs nulles
Analyse de donnees	Identification des tendances, classements et indicateurs de performance

8.4 - Difficultés Rencontrées et Solutions

Difficulté	Solution apportee
Gestion de 4 lookups simultanement dans JOB_05_FACT_MATCHES	4 composants tDBInput relies a un seul tMap central : resolution independante de chaque FK
Noms de stades incoherents entre CSV et MySQL	Table de correspondance manuelle dans tMap : normalisation avant insertion
Valeurs nulles dans les données joueurs (champ buts)	tFilterRow_1 dans JOB_03_DIM_PLAYERS : exclusion des lignes sans identifiant
Double relation dim_team vers fact_matches (home + away)	USERELATIONSHIP() dans les mesures DAX Power BI pour activer la relation inactive
Encodage des caracteres arabes et speciaux	Configuration utf8mb4_0900_ai_ci dans MySQL — set character utf8mb4 dans Talend

8.5 -Perspectives d'Amélioration

Plusieurs evolutions sont envisageables pour enrichir ce projet dans le cadre d'un approfondissement futur :

Ajout d'un module de Machine Learning (AI) pour la prediction des resultats de matchs (regression logistique, arbres de decision) sur la base des statistiques historiques.

Migration vers le Cloud (Azure Synapse Analytics ou Google BigQuery) pour une meilleure scalabilite et un acces distant au tableau de bord (optimisation et la performence du DATA CLOUD)

Publication sur Power BI Service avec actualisation programmee des données et partage securise entre les membres de l'equipe.

Integration d'une API football en temps reel (API-Football, Sportmonks) pour suivre les prochaines editions de l'AFCON en quasi-direct.

Automatisation du pipeline ETL via Apache Airflow ou un ordonnanceur pour planifier les executions Talend a frequence reguliere.

Extension du perimetre aux championnats domestiques des joueurs convoqués pour enrichir l'analyse des performances individuelles.

8.6 - Mot Final

Ce projet représenté une application concrete et complete des enseignements du Master SIDI, en particulier dans les domaines de l'integration de donnees, de la modelisation dimensionnelle et de la visualisation decisionnelle, Il illustre la faisabilité d'un visualisation de BI fonctionnel, du CSV brut au tableau de bord interactif, en utilisant uniquement des outils open source ou librement accessibles.

La richesse des données de l'AFCON 2025 - 52 matchs, 555 joueurs, 24 équipes, 8 stades , a fourni un terrain applicatif idéal, alliant volume suffisant, diversite des metriques et pertinence analytique pour une competition de renommée internationale organisée sur le sol marocain.

9. Bibliographie

[1] Documentation MySQL 8.0 : Oracle Corporation. MySQL 8.0 Reference Manual. https://dev.mysql.com/doc/refman/8.0/en/

[2] Talend Open Studio : Talend Documentation. Talend Open Studio for Data Integration. https://help.talend.com/

[3] Microsoft Power BI : Microsoft Documentation. Power BI. https://docs.microsoft.com/fr-fr/power-bi/

[4] DAX Reference : Microsoft. DAX Function Reference. https://docs.microsoft.com/en-us/dax/

[5] Data Warehouse Toolkit : Kimball, R. & Ross, M. (2013). The Data Warehouse Toolkit, 3e edition. Wiley.

[6] FootyStats : FootyStats.org (2025). AFCON 2025 Statistics Dataset. https://footystats.org/

[7] CAF Official : Confederation Africaine de Football (2025). Resultats AFCON 2025. https://www.cafonline.com/

[8] BeautifulSoup / Scrapy : Python Software Foundation. Web Scraping with Python. https://docs.python.org/